

Data Scientist/ Data Analyst Portfolio

Data Science, Data Analysis, Data Engineering, Project Design, Project Management

Kwangmin Kim

2025-07-16

[자연어 처리(NLP)를 활용한 Data Governance 시스템 단계적 구축]

프로젝트 개요

- 대내적 의의: 전사 자동화 시스템 구축의 시발점
 - 실험 자동화, 시약 개발 자동화, 분석 자동화, 의사 결정 자동화
- 대외적 의의: 글로벌 기술 공유 사업의 시발점
 - Microsoft, Springer Nature, KPMG, 각 국 정부기관 및 기업 등
- 총괄장 수명 프로젝트
- 기간
 - Phase1: 2024.10 ~ 2025.09 (진행중)
 - Phase2~3: 2025.10 ~ 2027.09
- 역할: Technical Lead
 - 표준화 체계 구축, Governance Architecture 설계, 표준화 프로세스 시스템 구축
 - 1명의 Junior Data Scientist 멘토링: 문제정의, 통계 및 데이터 분석 역량 강화
 - 12명의 IT/BT 개발자 멘토링: 데이터 거버넌스 70% 이해도 달성

주요 문제점 및 도전과제

- 문제점
 - 16개 부서 53개 DB의 메타데이터 불일치로 인한 데이터 활용도 저하 문제
 - 데이터 거버넌스 체계 부재
 - Data Silo 현상, 데이터 통합 및 검증 체계 부재
- 도전과제
 - 표준화 체계 구축
 - * 문제: 독립적으로 개발된 시스템 및 외주 개발 시스템 통합 불가
 - * 해결방안: 표준화 현황 분석 및 표준화 프레임워크 확립
 - 데이터의 품질 평가 자동화
 - * 문제: 영문 약어 생성 규칙 구현의 어려움 & 표준화 KPI (품질 평가 지표) 부재
 - * 해결방안: 계층적 Rule Engine 설계 & 원칙 기반 평가 지표 개발
 - BT & IT 용어 표준화
 - * 문제: (관용어 vs 표준화 원칙) & (SI 단위계 vs 업계 관행)
 - * 해결방안: 업무 전문가와의 협업을 통한 사전 구축
 - 조직내 낮은 Data 성숙도 및 교육의 어려움
 - * 문제: 임원진과 실무진의 막연한 두려움 & 표준화 지식 부족
 - * 해결방안: 추상적 개념 구체화, 동기부여 및 교육

솔루션 설계 및 전략




Figure 1: Data Standardization Framework

- Phase 1: Feasibility Test
 - 현실적 범위 설정 + 단계적 표준화 진행
 - 표준화 프레임워크 구축 (원칙 + 표준 사전 + 품질 평가)
 - 표준화 프로세스 반자동화 시스템 구축: Hybrid Rule Engine
 - * Rule Based 표준화 프로세스 구축
 - * Data Driven (딥러닝을 활용) 표준화 프로세스 병목 현상 해결
- Phase 2 ~ 3: 표준화 범위 확장
 - DB 확장 시 표준화 프로세스 시스템 확장
 - MS Azure Data Factory & Databricks 연동
 - 거버넌스 체계 구축, 표준화 교육 및 캠페인 진행
 - 표준화 모니터링 시스템 구축
 - 자동화 워크 플로우 구축
 - 데이터 활용방안 모색

기술 스택 및 요구 역량

- 데이터 처리: Python (pandas, numpy, regex, NLTK, konlpy)
- 자연어 처리: Pytorch (Hugging Face, Transformer, BiLSTM + Attention, ALBERT)
- 시각화 & 모니터링: Streamlit, matplotlib/seaborn, plotly
- RAG: Langchain, OpenAI, Hugging Face
- 워크플로우 자동화: Apache Airflow
- 기술적 역량
 - 복잡한 비즈니스 규칙의 알고리즘 설계 능력
 - 딥러닝 모델 설계 및 훈련 데이터 생성 능력
- 업무적 역량
 - 데이터 표준화 프레임워크 구축 (표준화 원칙 및 표준 사전 구축)
 - 도메인 전문가와의 협업 및 요구사항 분석
 - 표준화 정책 수립 및 이행 관리
 - 경영진 및 실무진과의 커뮤니케이션 능력

결과 및 성과

- 정량적 성과: 데이터 품질 향상
 - 표준화 체계 수립: 0% → 100% (최초 구축)
 - 메타데이터 완전성: 29.6% → 100% (80.4% 개선)
 - 메타데이터 일관성: 8.4% → 100% (91.6% 개선)
- 효율성 개선
 - 물리명 규칙 검증 시간: 수동 4시간 → 자동 0.73초 (98% 단축)
 - 약어 생성 정확도: 수동 생성 63% → 자동 100% (37% 향상)
 - 딥러닝을 활용한 표준화 프로세스 간소화: 도메인 분류 자동화
- 시스템 구축 성과
 - 품질 평가 프로그램 핵심 모듈 8개 개발
 - 표준화 세부 규칙 200여개 생성
 - 품질 지표 16개 개발 및 자동 산출 체계 구축
 - 자연어 처리(BiLSTM)를 활용한 용어별 도메인 그룹 분류
 - * 용어 중복 방지, 도메인 항목 관리 및 도메인 그룹 관리
 - * 예시: "USER_ID", "고객번호", "제품코드", "비밀번호", 등
 - 자연어 처리(ALBERT, DBSCAN)를 활용한 용어 Clustering
 - * 유사 용어 그룹핑: 금칙어 관리 및 표준안 관리
 - * "사용자ID", "UserID", "User", "user_id" 등 금칙어 관리
- 코드를 입력받아 LLM을 이용한 논리명 추천
- 논리명을 입력받아 물리명 추천
- 정성적 성과
 - 조직 차원: 16개 부서 통합 데이터 표준 확립
 - 데이터 기반 의사결정 지원 체계 마련
 - 표준화 정책 수립 및 거버넌스 체계 구축

기대효과

- 단기 기대효과
 - 운영 효율성
 - 데이터 통합 작업 시간 50% 단축
 - 신규 시스템 구축 시 표준 적용 자동화
 - 데이터 품질 이슈 사전 예방 체계 확립
- 비즈니스 가치
 - 데이터 표준화 체계 구축으로 데이터 활용도 향상
 - 부서 간 데이터 공유 활성화
 - 규제 대응 및 감사 준비 시간 단축
 - 실험 자동화 시스템 구축
 - 실험 데이터 모니터링
 - 글로벌 기술 공유사업 본격화

추후 과제

- 표준화 범위 확대
- Airflow를 활용한 자동화 워크플로우 구축
- 표준 사전 및 DB 메타데이터 데이터베이스 연동
- 모니터링 및 성능 최적화

[Real-Time PCR 진단 시스템을 위한 지능형 신호 처리 프레임워크]

프로젝트 개요

- Rule Based 진단 알고리즘을 Data Driven 알고리즘으로의 점진적 개선
 - 기존 rule-based 알고리즘의 한계로 인한 다양한 PCR 신호 패턴 대응 부족
 - 표준화되지 않은 baseline fitting 알고리즘 사용으로 인한 일관성 문제
 - 진단 정확도 향상 및 위양성/위음성 결과 최소화
- 기간: 2024.01 - 2024.07 (6개월)
- 팀 구성: 3명 데이터 사이언티스트, 2명 데이터 엔지니어, 2명 생물학자
- 역할: Project Manager & Data Scientist
- 참여 인원: 3명의 데이터 사이언티스트, 2명의 데이터 엔지니어, 2명의 생물학자

주요 문제점 및 도전과제

- 기술적 문제점
 - 신호 노이즈 복잡성: 화학/광학/기계적 반응의 측정 불가능한 노이즈 패턴
 - 알고리즘 분산화: 여러 baseline fitting 알고리즘 병존 및 소통 장애
 - Gray Zone 신호: 시약 성능 및 환경 요인으로 인한 모호한 판독 구간 존재
- 운영적 도전과제
 - 데이터 파이프라인 부재: 체계적인 신호 데이터 수집 및 분석 프로세스 미구축
 - 성능 평가 기준 부재: 객관적인 알고리즘 성능 비교 메트릭 부족
 - 주관적 신호 선별: 1년간 수동으로 특이 신호를 육안 식별하는 비효율적 프로세스
- 제약 조건
 - 호환성 요구: Python에서 C++로의 원활한 포팅을 위한 최소 패키지 사용
 - 이해관계자 다양성: 생물학자, 비전문가 임원 등 다양한 배경의 stakeholder 고려
 - 적은 데이터 포인트: 제한적인 baseline 데이터에서의 robust 알고리즘 필요

솔루션 설계 및 전략

1. 데이터 파이프라인 구축
 - 다양한 PCR 신호 패턴 수집 및 전처리 자동화
 - MuDT 전/후 신호 처리 분석 체계 구축
 - 성능 평가를 위한 end-to-end 데이터 처리 워크플로우




Figure 2: Data Pipeline

2. 알고리즘 비교 분석

- 1st Pannel [After BPN]: normalized **Raw Data**를 보여준다.
- 2nd Pannel [CFX]: (대조군1) 타사 기기전용 SW에 내재된 **Black Box** 알고리즘
- 3rd Pannel [DSP]: (대조군2) DS팀의 공식적으로 배포된 **Legacy Rule-Based** 알고리즘
- 4th Pannel [Auto]: (대조군3) 생물 실험자들이 사용하는 **Legacy Rule-Based** 알고리즘
- 5th Pannel [Strep+N]: (실험군1) N+1 번째 [DSP]를 보완용 **Rule-Based** 알고리즘
- 6th Pannel [ML]: (실험군2)본인의 특성방정식을 활용한 **data driven ML** 알고리즘
 - Talyer Series에서 초월 함수를 다항식의 조합으로 근사할 수 있다는 점에서 착안
 - 다항식 기저 함수를 사용한 선형 회귀로 데이터를 적합하는 방법을 시도
 - feature space를 확장하고, 데이터 내 복잡한 비선형 관계를 모델링 가능
 - 적절한 차수 선택과 정규화를 통해 baseline 신호에 적합
 - 로그 정규화 > 기저 함수 > 특성 방정식 > 비용 함수 > 그래디언트 > Momentum > 예측 > 역정규화

3. 시각화 중심 검증 체계: 비전문가를 위한 직관적 성능 평가

- 복수 신호 분석: 6개 알고리즘의 총체적 성능 비교
- 단일 신호 분석: 특이 신호에 대한 세부 성능 평가
- 신호 유형별 분석: 증가/감소/MuDT 특이 신호 패턴별 성능 검증

기술 스택

- 언어: Python (C++ 포팅 고려), Matlab (Legacy 알고리즘))
- 라이브러리: NumPy, Pandas (최소화 정책)
- 시각화: Matplotlib, Plotly
- 수학적 구현: 특성방정식, 신경망 (without Pytorch, Tensorflow, Keras)

결과 및 성과

- 알고리즘 성능 검증
 - ML 알고리즘: White noise에 가장 근접한 차감 결과로 최우수 성능 입증
 - 개선된 Rule-based: 기존 대비 특이 신호 처리 능력 향상
 - Black Box 알고리즘: 업계 1위 타사 알고리즘과 성능 비교 완료
- 프로세스 개선
 - 개발 프로세스 표준화: 시약 개발 시 일관된 알고리즘 적용 체계 구축
 - 검증 체계: 정성적 평가 방법론을 통한 알고리즘 성능 검증 프레임워크
- 시스템 개선
 - 표준화: 분산된 baseline fitting 알고리즘의 단일화 방향 제시
 - 자동화: 수동적 신호 선별 과정을 체계적 파이프라인으로 대체
 - 시각화 도구: 비전문가도 이해 가능한 직관적 성능 비교

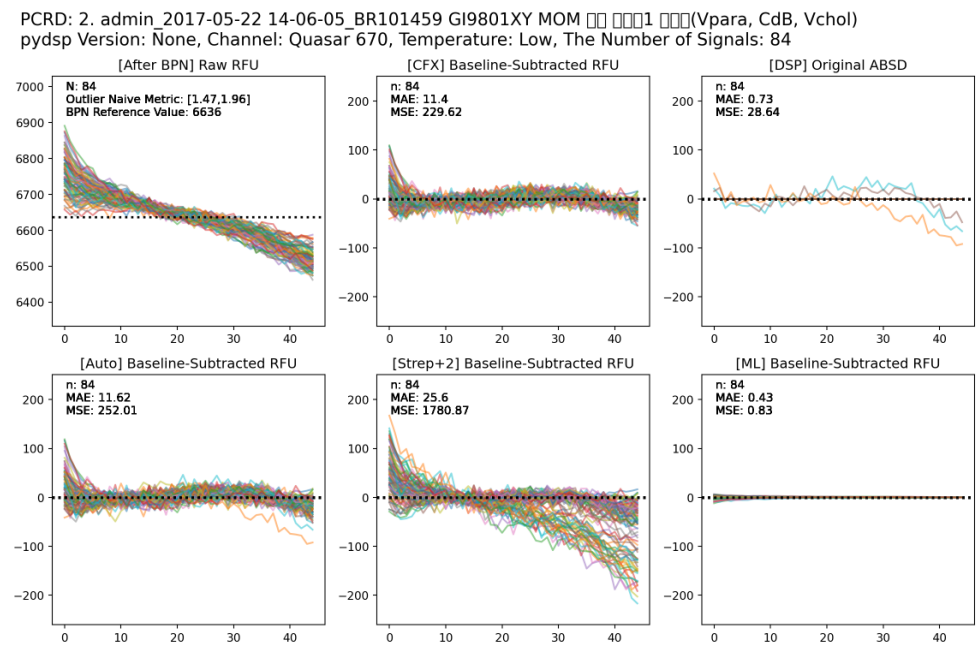


Figure 3: 알고리즘별 복수 신호 성능 비교

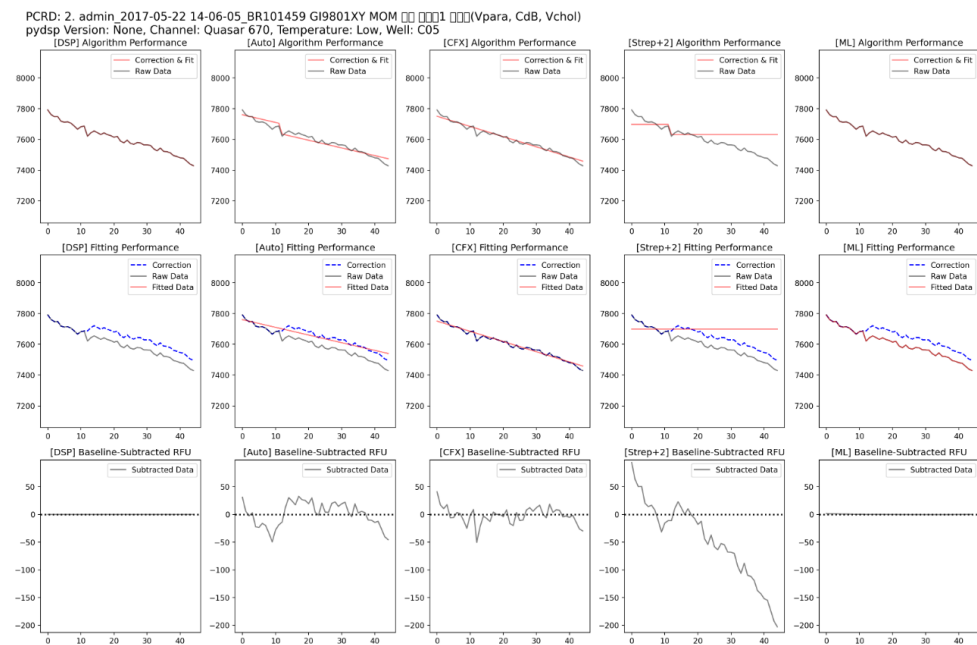


Figure 4: 알고리즘별 단일 신호 성능 비교

기대효과

- 즉시적 효과
 - 진단 정확도 향상: 위양성/위음성 결과 감소로 환자 안전성 제고
 - 개발 효율성: 표준화된 알고리즘으로 시약 개발 시간 단축
 - 품질 일관성: 단일화된 baseline fitting으로 제품 간 성능 편차 최소화
- 장기적 영향
 - 규제 대응 강화: V&V 프로세스 기반의 알고리즘 검증 체계 구축
 - 기술 경쟁력: Data-driven 접근으로 차세대 진단 알고리즘 기술 확보
 - 확장성: 다른 진단 알고리즘 영역으로의 방법론 확산 가능
- 비즈니스 가치
 - 시장 차별화: 업계 최고 수준의 신호 처리 기술 확보
 - 리스크 관리: 진단 오류로 인한 법적/재정적 리스크 감소
 - 혁신 문화: data-driven 의사결정 문화 확산의 기반 마련

[알고리즘 안전성 인허가 통계 분석 보고서 작성 반자동화]

프로젝트 개요

- 북미 진단 시장 진출을 위한 알고리즘 안전성 검증용 통계 분석 문서 작성 반자동화
- 의료 장비 및 시약 제품의 글로벌 진출 시 각국 정부의 규제 사항 존재
 - 시약의 안정성 검증
 - 장비의 안정성 검증
 - 진단 알고리즘의 안정성 검증
- EU: IVDR (In Vitro Diagnostics Regulation) 준수 필요
- 북미: FDA(미국) 및 Health Canada의 세계 최고 수준 엄격한 기준 충족 필요
- 기존 Software Engineering 방식보다 더 엄격한 **Advanced Testing** 요구
- 소프트웨어 및 알고리즘 규제 강화 추세

솔루션 설계 및 전략

- 알고리즘 안전성을 통계적으로 입증하는 시스템 기획
- **Statistical Validation System** 확립을 통한 통계적 분석 입증
- 알고리즘 리스크 정의 및 정량적 영향도 분석
- 코드 변화 대응을 위한 자동화 시스템 구축
- **SGS 가이드스(EN62304)** 참고
- **FDA General Principles of Software Validation** 문서 기반 시스템 확립
- **Structural Testing** (코드 기반) + **Statistical Testing** (통계 분석 기반) 병행
- Seegene BT(생명공학)와 IT(정보기술) 부문 협력 체계 구축
- 창의적 Testing Model 기획 및 Statistical Analysis Design 구체화

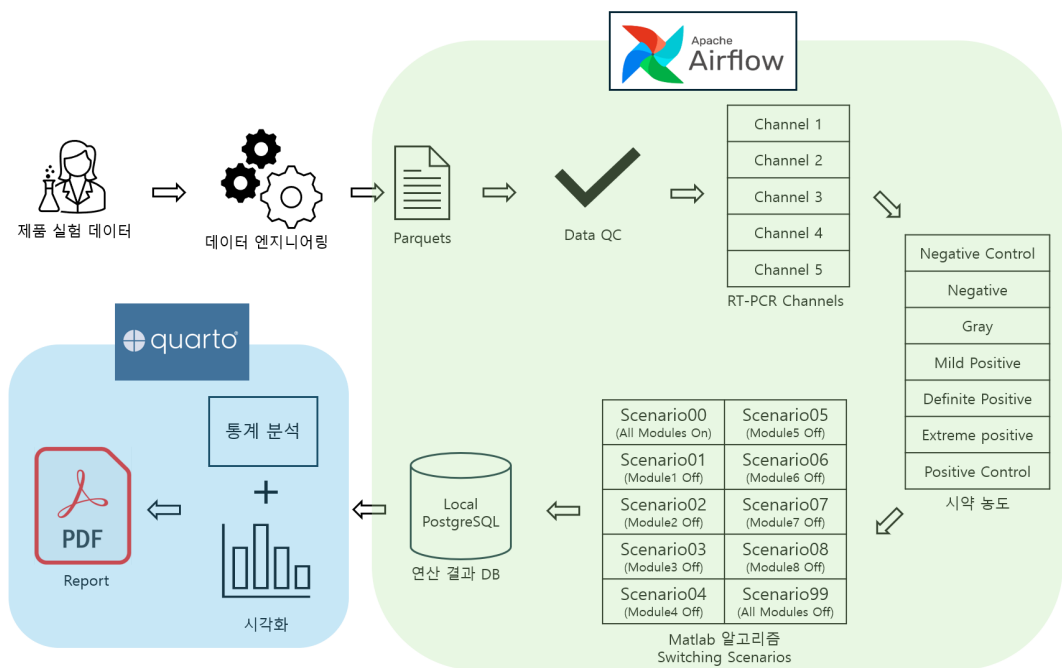


Figure 5: Data Pipeline

주요 도전과제 및 해결방안

- 문제: BT 부서 생성 데이터 입력 시스템 부재
- 해결: 실험 설계 파일, 의료기기 원시 데이터, 추출 데이터의 **디지털화 시스템** 구축
- 문제: BT 및 Data Science 팀 업무 기술서 부재
- 해결: 부서간 협업을 통한 **업무 문서화** 진행 및 기대 정답 기준 확립
- 5단계 Data QC Process 강화
 1. 오타 교정
 2. 결측치 처리
 3. 이상 데이터 처리
 4. 알고리즘 데이터 정합성 1차 검증
 5. 알고리즘 데이터 정합성 2차 검증

기술 스택 및 요구 역량

- 규제 지식: FDA Software Validation
- 통계 분석: Statistics (2-Way Repeated Measures ANOVA), Clinical Study Design
- 프로그래밍: R (Statistical Testing), Python (Engineering), Matlab (진단 알고리즘)
- 워크플로우: Apache Airflow
- 문서 자동화: Quarto
- 도메인 지식: Biology

결과 및 성과

5.3.1 Target Template S

In the target template S, the DSP algorithm showed 100% accuracy on average with 0% standard deviation across both the concentration and scenario levels (See Figure 5.2).

- For NC signals, the DSP algorithm scenarios showed 99.7753% accuracy with the standard deviation, 0.4552%.
- For PC signals, the DSP algorithm scenarios showed 99.8876% accuracy with the standard deviation, 0.3414%.
- scenario00 showed 100% accuracy on average across the different concentration levels with 0% standard deviation and .
- scenario99 showed 97.027% accuracy on average across the different concentration levels with 6.8398% standard deviation.
- scenario02 recorded the lowest accuracy, 97.027% with the standard deviation 6.8398% across the concentration levels.
- scenario02 recorded the highest standard deviation of accuracy, 6.8398%.
- the DSP algorithm scenarios showed the lowest accuracy 96.1202% with the standard deviation, 7.8584% in the negative concentration.
- The lowest accuracy of scenario02 in the negative concentration results from the false negatives, 0 cases and the false positives, 413 cases with the p-value, < 0.001 (See Table 5.4 and Table 5.5).
- A list of false negative and false positive cases related to concentration levels and scenarios is displayed in Table 5.6.

Table 5.4: Frequency Summary of DSP Performance for the Negative Concentration						
template	concentration	scenario	false_negative	false_positive	true_negative	true_positive
S	negative	scenario00	0	0	2129	0
S	negative	scenario01	0	0	2129	0
S	negative	scenario02	0	413	1716	0
S	negative	scenario03	0	0	2129	0
S	negative	scenario04	0	0	2129	0
S	negative	scenario05	0	0	2129	0
S	negative	scenario06	0	0	2129	0
S	negative	scenario07	0	0	2129	0

59

(continued)						
template	concentration	scenario	false_negative	false_positive	true_negative	true_positive
S	negative	scenario08	0	0	2129	0
S	negative	scenario99	0	413	1716	0

Figure 6: Report

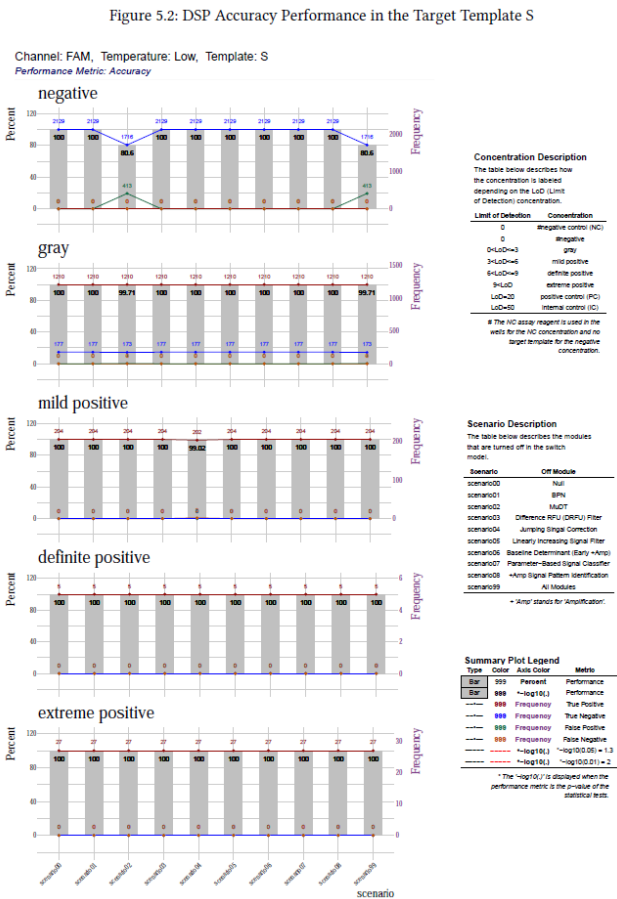


Figure 7: Plot

- DSP Algorithm 결과물
 - FDA 제출용 verification & validation report 초안 완성
 - 문서화 시스템: 업무 소통 및 RDB 시스템 구축을 위한 자동화 시스템
 - 데이터 관리 시스템: Data Quality Control System 구축
 - FDA Validation Model: DSP 알고리즘 전용 Validation Model 확립
 - 특허 발명: FDA Validation Model 관련 특허 출원
 - 성능 평가 체계: 사내 최초 알고리즘 및 시약 제품 종합 성능 평가
 - 리스크 관리 통계 분석: 시약/장비 고유 효과 및 교란 요인 위험 관리 분석

기대효과

- 북미 시장 진출을 위한 FDA 규제 대응 체계 확립
- 알고리즘 안전성에 대한 통계적 증명 체계 구축
- 문서 자동화를 통한 업무 효율성 향상
- 시약, 장비, 소프트웨어 및 알고리즘 통합 인허가 시스템 구축

[진단 장비 QC 프로세스 자동화 및 알고리즘 고도화 프로젝트]

프로젝트 개요

- PCR 진단 시약을 타사 장비 공급업체의 장비에 탑재
- 진단 서비스 결과의 정확도를 위해 **2 Step 장비 QC 프로세스**를 통해 장비의 성능 평가
- 프로젝트의 목적: 1. 부정확한 **QC 알고리즘 개선** 2. 투입 리소스가 많은 **QC프로세스 과정을 간소화**시켜 현업의 부담을 경감
- 프로젝트 기간: 9개월
- **2 Step QC Process**
 - QC Step 1: 자사 시약에 맞게 장비간 **신호 Scale Calibration**
 - QC Step 2: 장비의 성능을 평가하여 **합격/불합격 분류** - 문제점 발생
 - * 엑셀을 이용한 **수동검사**, 비효율적인 **데이터 및 장비 추적 관리**
 - * 수동 검사 과정에서 신호의 증폭 크기에 따라 **왜곡된 QC 결과** 발생
 - * **기계 결함 및 휴먼 에러 구별 불가**



Figure 8: 기존 QC 프로세스

솔루션 설계 및 전략

- Data Engineering: 산재된 **Excel QC data** ETL
- QC Step2의 **장비 성능 평가 지표**를 생성하여 장비 성능 측정 고도화
- **합격/불합격 분류** 뿐만 아니라 **장비 등급**을 차등 부여하여 고객사에 차등 공급
- 시간에 따른 **장비의 성능**을 지속적으로 **모니터링**하여 장비의 성능 분석
- **QC Process 간소화**
 - QC Step 1 데이터를 통해 QC Step 2 결과를 예측하는 **딥러닝 모델 개발**
 - 예측 결과로 장비성능이 Fail로 확실시 되는 장비에 한해서 QC Step 2 검사 진행
 - Web App 로 분석 결과 및 시각화 Dashboard 제공
 - 실무 담당자가 데이터 업로드 하면 자동으로 분석 결과 제공

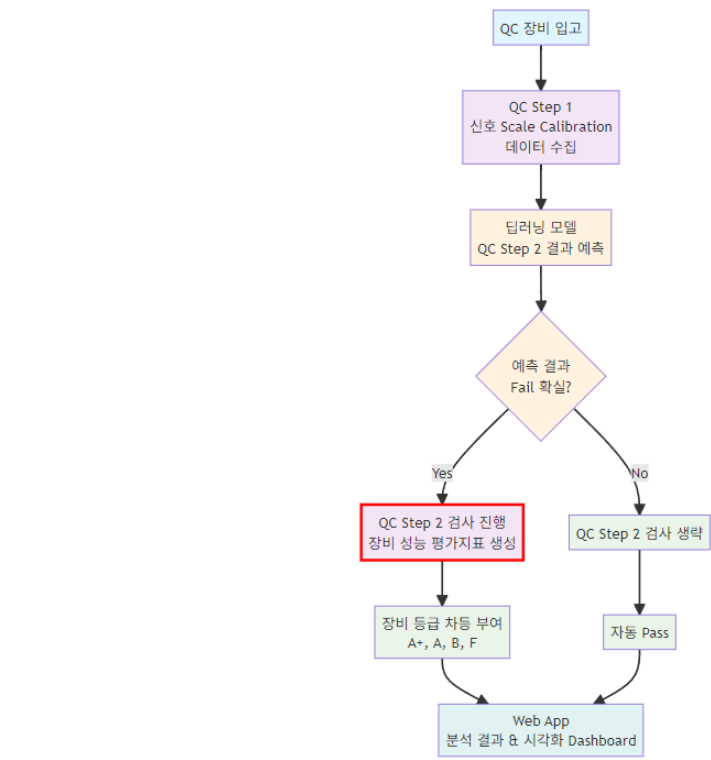


Figure 9: 개선된 QC 프로세스

기술 스택 및 요구 역량

- 데이터 엔지니어링: QC Data ETL
- 머신러닝: Clustering (PCA, t-SNE, DBSCAN), Anomaly Detection (Isolation Forest), Outlier Detection (IQR, Z score, 3-Sigma Rule)
- 딥러닝: Pytorch (LSTM), scikit-learn
- 통계/신호처리: SNR, RSS 계산, 시계열 분해 등
- 웹앱 개발: R Shiny (대시보드 및 시각화)
- 도메인 지식: PCR 기술, 의료기기 QC, 통계적 공정관리, 광학 장비 성능 평가

결과

- PCR기기 2201대를 2552번의 실험해서 만들어진 61,248개의 신호 데이터 확보
- QC Process Step 2 장비 성능 평가 메트릭 생성
 - 신호 증폭 효율성 측정
 - SNR (Signal to Noise Ratio) 측정
 - 기준선 안전성 측정
 - 광학 균일성 측정
 - 장비 온도 균일성 측정
 - 음성 신호 추세 측정
 - 양성 신호 노이즈 측정
 - 시계열 분해 기반 노이즈 측정

- Outlier 및 Anomaly Data 탐지로 labeling (IQR, Z score, PCA, t-SNE, DBSCAN, 3-Sigma Rule, Isolation Forest)
- 신호 RSS (Residual Sum of Squares) 측정
- 평가 메트릭 QC 등급 분류: Pass (A+,A,B), Fail (F)




Figure 10: 장비 성능별 클러스터링

- LSTM을 활용한 Step 1 데이터를 통한 Step 2 결과 예측 모델 개방
 - 합격/불합격 분류 정확도: 99.3%
 - 장비 성능 등급 분류 정확도: 91.7%

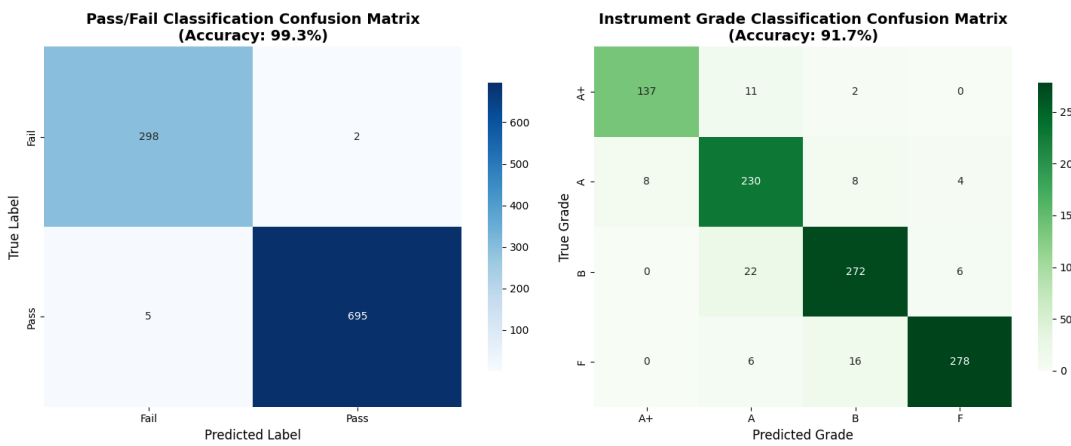


Figure 11: BiLSTM Confusion Matrix

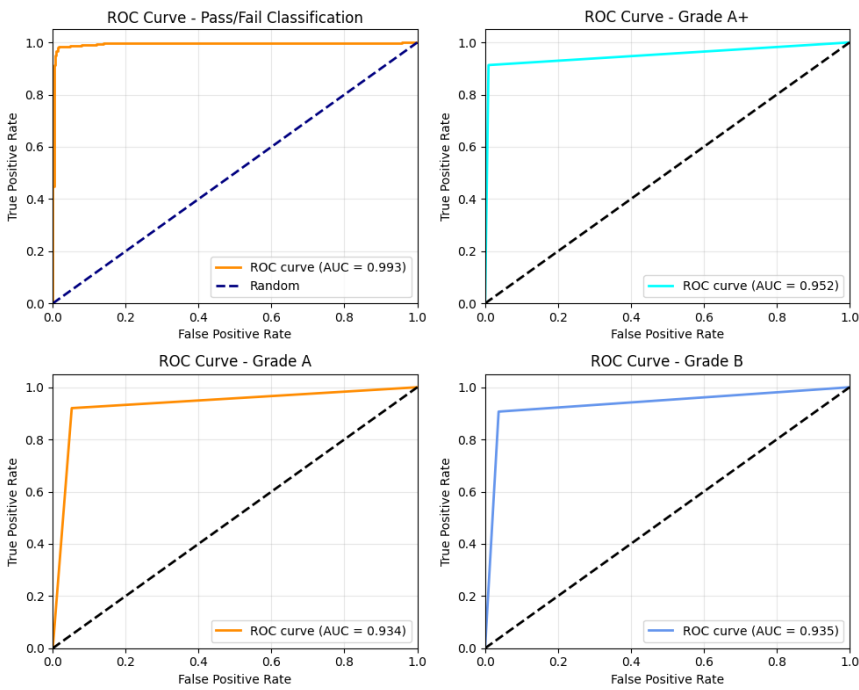


Figure 12: BiLSTM ROC Curve

- Web App Dashboard Prototype 개발
 - 실무자가 데이터 업로드 하면 자동으로 분석 결과 제공
 - 시각화 및 데이터 관리 기능 제공
- 총괄장 R&D 부문 우수상 수상 및 2개의 특허 출원

기대효과

- 편의성 증가: QC시간 약 14배 감소
 - (As-Was: 약 400시간/100대) vs (As-Is: 약 28시간/100대)
- 웹 기반 자동화 플랫폼 제공
 - 연간 비용 약 13배 감소 (QC 시간 및 약 6억원의 비용 감소)
- Mechanical Engineers의 신기술 개발 지원

[치매 Biomarker 규명: 대사체 통계 분석 및 머신러닝 방법론 비교 연구]

개요

- 2차 세계 대전 후 Baby Boomer 세대의 대규모 치매 발병에 대비한 치매 인자 규명
- 모집단: 장수마을에 거주하는 백인 참여자 (LLFS - Long Life Family Study)
- 기간: 2018.12 - 2020.04 (17개월)
- 역할: Research Statistician
- 참여 인원: 23명 (Epidemiologists, 생물통계학자, 유전통계학자, 신경외과 의사, 생화학자, 임상연구 코디네이터, 데이터 엔지니어)

주요 문제점 및 도전과제

- 의학적 문제점
 - 알츠하이머병은 증상 발현까지 20년간 진행되어 전임상 단계 생리학 이해 필요
 - 유전적 요인이 알츠하이머병에 50% 기여하나 구체적 메커니즘 불명
 - APOE 유전자 보유자의 대사체 변화 패턴 미규명
- 데이터 분석적 도전과제
 - 다중 센터 데이터 수집으로 인한 데이터 품질 불일치
 - 고차원 데이터 (약 3,000개 변수) 대비 작은 표본 크기 (146개 관측치)
 - Mass Spectrometry 데이터의 복잡한 결측치 및 이상치 패턴
 - Multiple testing으로 인한 1종 오류 증가 위험
- 연구 환경적 제약
 - 8개월간 연구소에서 파악하지 못한 강력한 교란자 존재
 - 유전체, 전사체, 단백질체, 대사체 다층 분석 필요성
 - 다학제 팀 간 소통 및 결과 공유 복잡성

솔루션 설계 및 전략

- 데이터 수집 및 전처리 파이프라인
 - 다중 센터 (New York, Boston, Pittsburgh, Denmark) 혈액 샘플링
 - Mass Spectrometry를 통한 대사체 데이터 디지털화
 - 체계적 데이터 품질 관리 프로세스 구축




Figure 13: Data Pipeline

- 데이터 품질 관리 (QC) 전략
 - 이상치 및 결측치 식별: 생화학자와의 협업을 통한 실험실 기준 적용
 - Missing Value Analysis: MCAR, MAR, MNAR 분류 및 처리 방안 결정
 - 데이터 포함/제외 기준: rowwise 및 columnwise 결측치 비율 5% 기준 적용
 - 데이터 전처리: Log transformation 및 Standardization
- 3단계 분석 파이프라인
 - 1단계 - EDA & Data Mining & 임상 지식: 패턴 발견 및 교란자 규명
 - 2단계 - Statistical Analysis: 다변량 회귀분석 및 생존분석
 - 3단계 - Machine Learning: 다양한 알고리즘 성능 비교 및 최적 모델 선택

기술 스택 및 요구 역량

- 프로그래밍: R (Tidyverse, ggplot2, mixOmics, survival, glmnet, etc.)
- EDA: Student t-tests, Wilcoxon Mann-Whitney tests, χ^2 tests, Fisher Exact Tests, ANOVA, Kruskal-Wallis Tests
- 통계분석: Linear regression, Logistic regression, Cox Proportional Hazards regression, Linear Mixed Effect Model, GWAS, Multiple Comparison Tests
- 머신러닝: Lasso, Ridge regression, Elastic net, Random forests, AdaBoost, Gradient boosting, SVM, PLS, Sparse PLS

- 데이터 마이닝: KNN, PCA, K-means clustering, DBSCAN
- 통계적 검증: Permuted p-values를 통한 multiple correction
- 도메인 지식: 생리학, 생화학, 신경의학*, 역학, 생물통계학, 유전학
- 협업 역량: 다학제 팀 (의사, 생물학자, 생물정보학자, 역학자) 소통

결과

- Metabolic Pathway Map 제시
- EDA 및 Data Mining을 통한 미지의 강력한 교란자 규명
- 약 3,000개 대사물질 중 약 60개가 질병과 5% 유의수준에서 유의한 관련성 있음
- 약 60개 중 13개의 대사물질이 질병과 1% 이하의 유의수준에서 유의한 관련성 있음
- GWAS를 통해 유의한 대사물질과 유의한 관련이 있는 유전자 규명
- Sparse Partial Least Squares가 최적 성능의 분류기로 선정




Figure 14: EDA: Correlation Plots between Metabolites and Phenotype




Figure 15: 일부 GWAS 결과

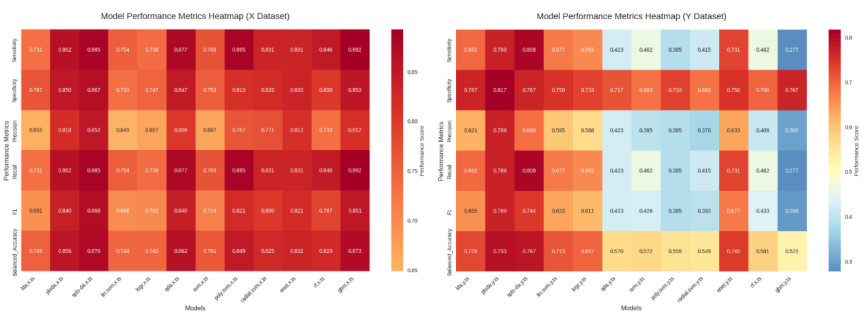


Figure 16: ML Classifier Performance

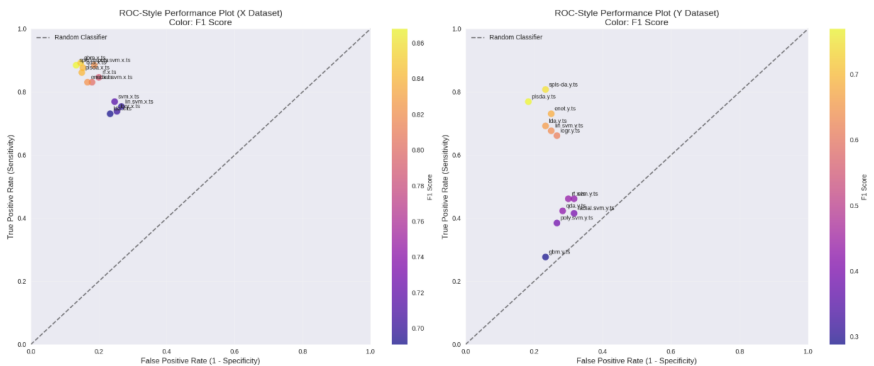


Figure 17: ML Classifier ROC

성과 및 기개효과

- Columbia University Mailman School of Public Health 연례 연구 발표회 포스터 발표
- 연례 연구 경진대회에서 약 100명의 대학원생 중 상위 3명 선정, 상금 \$1,000 수상
- 학과장상 수상
- Columbia University Irving Medical Center 신경외과 정규직 Job Offer 획득
- 고차원 대사체 데이터에 대한 체계적 분석 파이프라인 구축
- 다학제 협업 연구 모델 및 분석 방법론 제안
- 알츠하이머병 치료제 개발을 위한 타겟 발굴 기여